



UNIVERSIDAD DEL BÍO-BÍO

Universidad del Bío-Bío
Facultad de Ciencias

Certamen 2 Linux

Tema: Procesamiento de Datos con NuShell

Alumna: Rafaella Puchi Vásquez

Profesor: Luis Gomez

Fecha de entrega: 28 de Diciembre 2025

Índice

1. Introducción	2
2. Metodología	2
2.1. Lectura de datos	2
2.2. Selección de variables	2
2.3. Limpieza de datos	3
2.4. Generación del archivo final	3
3. Análisis de Resultados	3
4. Reproducibilidad	4
5. Conclusiones	4

1. Introducción

El presente informe técnico documenta el proceso de limpieza, transformación y reducción de una base de datos de matrícula de educación superior, utilizando el entorno Linux y el shell estructurado NuShell. El objetivo principal fue generar un archivo de salida limpio y reproducible, cumpliendo con los requisitos establecidos en el certamen.

2. Metodología

El procesamiento de los datos se realizó mediante un script desarrollado en NuShell, siguiendo una secuencia estructurada de comandos.

2.1. Lectura de datos

El archivo original fue entregado en formato TXT separado por tabulaciones. Para su correcta interpretación se utilizó el comando:

```
open estudio_mercado_ordenado.txt --raw | from tsv
```

Esto permitió cargar la información como una tabla estructurada, respetando las columnas originales del conjunto de datos.

2.2. Selección de variables

Dado el gran número de variables disponibles, se realizó un filtrado seleccionando únicamente las columnas relevantes para el análisis:

- Año de matrícula
- Total de matriculados
- Matrícula de primer año
- Institución
- Sede
- Carrera

El comando utilizado fue:

```
select "AÑO" "TOTAL MATRICULADOS"
      "TOTAL MATRICULADOS PRIMER AÑO"
      "NOMBRE INSTITUCION"
      "NOMBRE SEDE"
      "NOMBRE CARRERA"
```

2.3. Limpieza de datos

La variable AÑO contenía un prefijo textual (MAT_), el cual fue eliminado para convertir la variable a un formato numérico. Este proceso se realizó mediante:

```
update "AÑO" {
  |r| $r."AÑO"
  | into string
  | str trim
  | str replace "MAT_" ""
  | into int
}
```

Posteriormente, se renombraron las columnas para facilitar su uso y legibilidad:

```
rename "AÑO" anio
      "TOTAL MATRICULADOS" total
      "TOTAL MATRICULADOS PRIMER AÑO" primer_anio
      "NOMBRE INSTITUCION" institucion
      "NOMBRE SEDE" sede
      "NOMBRE CARRERA" carrera
```

2.4. Generación del archivo final

Finalmente, se seleccionaron las columnas definitivas y se generó el archivo `datos_final_limpio.csv`:

```
select anio total primer_anio institucion sede carrera
| save --force datos_final_limpio.csv
```

3. Análisis de Resultados

El archivo final contiene información limpia y estructurada de la matrícula de educación superior correspondiente al año 2024.

Tras el proceso de filtrado, se obtuvo un conjunto de datos compuesto por múltiples carreras impartidas por distintas instituciones. La institución con mayor presencia en el conjunto de datos es la *Universidad Gabriela Mistral*, la cual concentra una gran cantidad de registros, principalmente en la sede Casa Central.

El archivo generado permite analizar la distribución de matrícula total y de primer año por carrera e institución, facilitando futuros análisis estadísticos.

4. Reproducibilidad

El proceso descrito es completamente reproducible. Cualquier usuario puede generar el archivo de salida ejecutando el script `script.nu` en un entorno Linux con NuShell instalado y ubicando el archivo original en el mismo directorio.

El repositorio GitHub contiene:

- El script de procesamiento (`script.nu`)
- El archivo CSV generado (`datos_final_limpio.csv`)
- El presente informe en formato PDF

5. Conclusiones

El uso de NuShell permitió realizar un procesamiento claro, estructurado y reproducible de una base de datos de gran tamaño. La combinación de filtrado, limpieza y transformación facilitó la generación de un archivo final adecuado para análisis posteriores. El flujo de trabajo implementado cumple con los requisitos del certamen y promueve buenas prácticas de reproducibilidad.